UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Ingeniería Industrial

Ciencia de Datos · Curso I5571 · 2026

TRABAJO PRÁCTICO FINAL

Predicción de bajas de clientes en una empresa de telecomunicaciones

Del análisis exploratorio a una regla de retención basada en costos

GRUPO 6

Iñaki Hegoburu	Legajo 1593973
Guillermo Inostroza	Legajo 1764111
Julián Longo	Legajo 2042873
Erik Yuji Tanaka	Legajo 1772752

Buenos Aires, 5 de noviembre de 2026

Resumen

Una empresa de telecomunicaciones quiere anticipar qué clientes se van a dar de baja para ofrecerles una acción de retención. Trabajamos con 7.043 clientes y 21 variables, con catorce columnas a las que les falta entre el 13% y el 17% de los valores. Apartamos un 20% de prueba antes de estudiar cualquier relación con la baja, completamos 3.398 faltantes con reglas que se deducen de la misma fila y armamos un pipeline que aprende el preprocesamiento solo con datos de entrenamiento. Elegimos la regresión logística porque empata con modelos más complejos y es la más simple de explicar. Con un umbral de 0,134, derivado de los costos de perder un cliente y de la oferta, el modelo detecta al 92% de las bajas del conjunto de prueba y cuesta un 26% menos que ofrecerle la retención a todos.

0,844	92%	−26%	0,134
AUC en prueba (IC 95%: 0,824 a 0,867), cercano al de validación cruzada (0,846)	de los clientes que se van, detectados con el umbral por costos	de costo frente a ofrecerle la retención a toda la cartera	umbral de decisión: oferta de 120 sobre pérdida de 897

1. Introducción y objetivos

Retener a un cliente suele costar menos que perderlo, pero ofrecerle un descuento a toda la cartera también cuesta, y buena parte de ese gasto se va en clientes que no pensaban irse. Por eso el problema tiene dos partes: ordenar a los clientes según su riesgo de baja (*churn*) y decidir desde qué riesgo conviene contactarlos. Nos propusimos justificar con evidencia cada decisión de preprocesamiento, elegir el modelo con reglas fijadas antes de ver resultados, convertir las probabilidades en una regla de acción con una matriz de costos y evaluar si el PCA ayuda a predecir. Tres notebooks (análisis exploratorio, manipulación de los datos y machine learning) reproducen todos los números de este informe.

2. Descripción del dataset

Cada fila es un cliente, con un identificador, tres variables numéricas (antigüedad en meses, cargo mensual y cargo total), dieciséis categóricas (datos demográficos, servicios contratados, tipo de contrato y medio de pago) y la variable objetivo. Se dio de baja el 26,5% (1.869 clientes): un clasificador que responde "nadie se va" acierta el 73,5% sin identificar a ningún cliente que se va, así que descartamos la exactitud como métrica. No hay duplicados ni valores imposibles, y las reglas de negocio entre columnas se cumplen en todas las filas. El problema son los faltantes. A catorce variables les falta entre el 13% y el 17% de los valores y, como caen en filas distintas, solo el 12% de los clientes tiene la fila completa: eliminar filas habría descartado al 88% de la muestra.

3. Análisis exploratorio de datos

Antes de estudiar cualquier relación con la baja apartamos el 20% de los clientes como conjunto de prueba (partición estratificada, semilla fija), para que ninguna decisión dependa de ellos (Géron, 2022, cap. 2). El análisis usa el 80% restante, 5.634 clientes.

Faltantes. Ninguno de 266 contrastes da significativo con la corrección de Bonferroni y una regresión logística no logra predecir qué celdas faltan (AUC entre 0,48 y 0,54). Por eso los tratamos como completamente aleatorios (MCAR, *missing completely at random*). Muchos se deducen de la misma fila: un cliente sin internet tiene "No internet service" en los seis servicios adicionales, y el cargo total se reconstruye con la antigüedad y el cargo mensual. Nueve reglas de este tipo recuperan 3.398 valores: cinco son exactas por definición, dos son regularidades sin excepciones en entrenamiento (los 425 clientes sin teléfono de entrenamiento tienen DSL), y las dos que reconstruyen la antigüedad y el cargo mensual se equivocan entre 15 y 32 veces menos que imputar la mediana. Como no aprenden nada de otras filas, da lo mismo aplicarlas antes o después de separar los conjuntos y no generan fuga de información. El resto de los faltantes lo imputa el pipeline. Después de las reglas, los huecos que quedan en los servicios pertenecen a clientes que sí tienen el servicio (son MAR, al azar condicionado a otra variable), y por eso el pipeline los marca con una categoría "Desconocido" en lugar de asumir un valor.

Quién se va. El contrato es la variable más asociada con la baja (V de Cramér 0,40): se va el 42% de los clientes mes a mes y el 3% de los de contrato bienal (Figura 1A). Le siguen la seguridad online y el soporte técnico (V de 0,36 y 0,35; se van más los que no los tienen), el tipo de internet (0,33; la fibra concentra las bajas), el medio de pago (0,32; sobre todo el cheque electrónico) y la antigüedad. Entre los clientes mes a mes con hasta seis meses de antigüedad se va el 55%, y la diferencia entre contratos se mantiene en todos los tramos (Figura 1B). En cambio, gender y PhoneService no muestran

asociación (V de 0,01 y 0,02). El cargo total tiene una correlación de 0,83 con la antigüedad y una asimetría de 0,95, dos motivos para probar una transformación logarítmica.

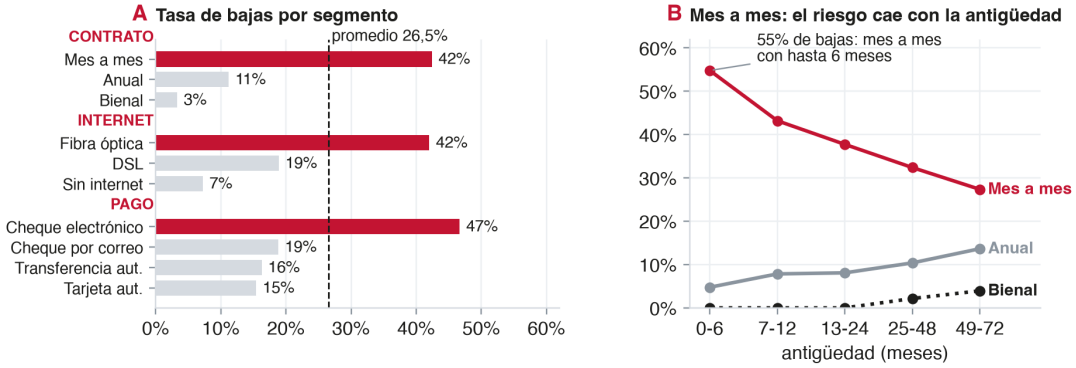


Figura 1. (A) Tasa de bajas por categoría; en rojo, las que superan el 40%. (B) Tasa de bajas por tramo de antigüedad según el contrato. Datos de entrenamiento.

Costos. El dataset no trae costos, así que los fijamos con un criterio explícito. Expresamos los costos en la misma unidad que el cargo mensual del dataset. Perder un cliente cuesta 897, doce meses del cargo medio de quienes se van (74,7): es el horizonte de un contrato anual y una aproximación simple del valor del cliente (Gupta et al., 2006). La oferta de retención cuesta 120, un descuento del 13% sobre ese año. Contactar a un cliente conviene cuando la pérdida esperada supera el costo de la oferta ($p \times 897 > 120$), es decir, cuando $p > 120 / 897 \approx 0{,}134$, donde p es la probabilidad de baja (Murphy, 2022, sec. 5.1.2.2).

4. Materiales y métodos

Separamos lo que no aprende de los datos, que se aplica una sola vez en el notebook de manipulación, de lo que sí aprende. La imputación, la codificación, el escalado y el PCA van dentro de un Pipeline de scikit-learn que se reajusta en cada fold (Figura 2; Pedregosa et al., 2011), así que ninguna estadística del fold de validación llega al modelo que se evalúa en él.

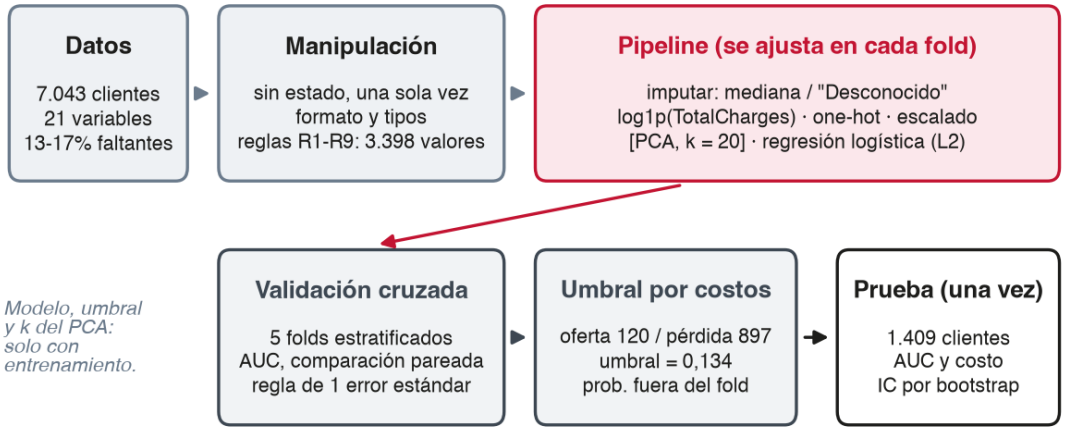


Figura 2. Flujo de trabajo. En gris, lo que se aplica una sola vez; en rojo, el pipeline que se reajusta en cada fold; abajo, la selección con datos de entrenamiento y la evaluación final.

Validación y reglas. Usamos validación cruzada estratificada de 5 folds sobre entrenamiento, con los mismos folds en todos los experimentos para comparar de a pares (James et al., 2023, sec. 5.1). La métrica es el AUC, que mide cuán bien se ordena a los clientes por riesgo sin depender del umbral (Hanley y McNeil, 1982). Fijamos las reglas antes de ver resultados, para no quedarnos a posteriori con la variante que mejor salió: un cambio de preprocesamiento se adopta si mejora el AUC en más de dos errores estándar de la diferencia pareada y en al menos 0,001, y entre modelos elegimos el más simple a menos de un error estándar del mejor (James et al., 2023, sec. 6.1.3).

Modelos y evaluación. Comparamos regresión logística con regularización L2, k vecinos, árbol de decisión, Random Forest (Breiman, 2001), gradient boosting (Friedman, 2001; Ke et al., 2017), una red neuronal de una capa oculta (Géron, 2022, cap. 10) y un ensamble por voto suave, con hiperparámetros elegidos por búsqueda en grilla. La logística estima $P(\text{baja} \mid x) = 1 / (1 + \exp(-(\beta_0 + \beta^T x)))$ minimizando la entropía cruzada más una penalización $\lambda\|\beta\|^2$ (scikit-learn la parametriza con $C = 1/\lambda$). El umbral se valida con probabilidades fuera del fold, después de comprobar que están calibradas (Niculescu-

Mizil y Caruana, 2005). El conjunto de prueba se usa una sola vez, con intervalos del 95% por bootstrap pareado (Efron y Tibshirani, 1993).

5. Experimentos y resultados

5.1 Preprocesamiento y elección del modelo

Partimos de una logística con el preprocesamiento más simple y cambiamos una decisión por vez (Figura 3A). Imputar las categóricas con una categoría "Desconocido" mejora en los cinco folds: la moda le asignaba "mes a mes" a 950 clientes sin contrato informado y diluía la variable más fuerte. Aplicar log1p al cargo total es la mejora más grande (+0,0045), porque la logística es lineal en sus entradas: el cargo total crece con la antigüedad, y en escala logarítmica sigue mejor la caída del riesgo, fuerte en los primeros meses y casi plana después. Tratar "No internet service" como "No" en los seis servicios adicionales (el tipo de internet ya lleva esa información) y quitar gender y PhoneService no cambian el AUC y ahorran 16 columnas. Quitar el cargo total empeora (−0,0053), y las demás variantes que probamos (tramos de antigüedad, imputar con k vecinos, pesos por clase) empatan.

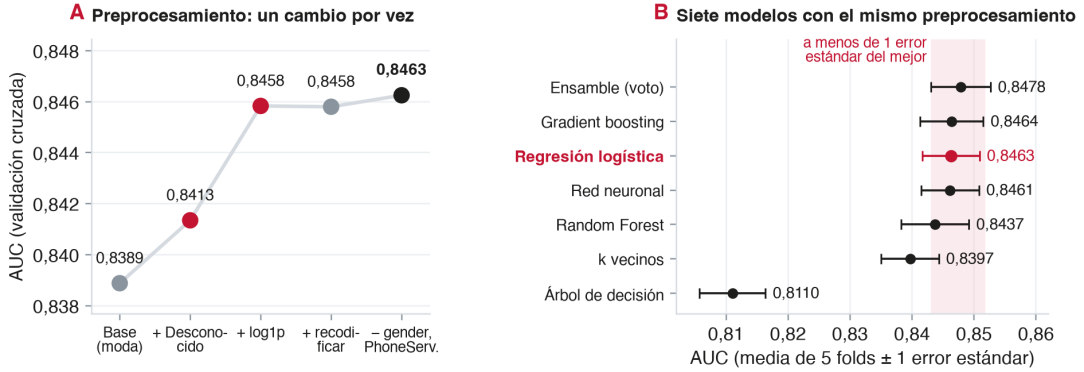


Figura 3. (A) AUC de la regresión logística en cada paso del preprocesamiento; en rojo, los pasos que mejoran el AUC en más de 0,001; en negro, la configuración final. (B) AUC de cada modelo con sus mejores hiperparámetros (media de 5 folds ± 1 error estándar; la Tabla 1 reporta el desvío entre folds); la franja marca los modelos a menos de un error estándar del mejor.

Con las 42 columnas fijas, los modelos quedan en un rango estrecho, de 0,840 a 0,848, salvo el árbol individual (0,811), que además es el que más sobreajusta (Figura 3B y Tabla 1). Un boosting de profundidad 1, que no puede combinar variables, llega a 0,8465: si un modelo sin interacciones rinde igual, la estructura del churn es casi aditiva, que es lo que supone la logística. El ensamble gana 0,0016 en 4 de los 5 folds, dos errores estándar de la diferencia pareada: con la regla del preprocesamiento quedaría justo en el límite. Para elegir modelo fijamos de antemano un margen más exigente, un error estándar del AUC medio (0,0048), porque un modelo más complejo cuesta más mantener y explicar que un cambio de preprocesamiento (James et al., 2023, sec. 6.1.3). Por esa regla elegimos el modelo más simple, la **regresión logística**: entre los que empatan es la que menos sobreajusta, se interpreta coeficiente por coeficiente y entrega probabilidades calibradas, la condición que necesita el umbral.

Tabla 1. Modelos con sus mejores hiperparámetros (validación cruzada de 5 folds sobre entrenamiento). El boosting de profundidad 1 (0,8465) se discute en el texto.

Modelo	Hiperparámetros	AUC (media ± desvío)	Brecha entren. − valid.
Ensamble por voto suave	logística + boosting	0,8478 ± 0,0108	no aplica
Gradient boosting	profundidad 2	0,8464 ± 0,0114	0,016
Regresión logística (elegido)	**C = 1, L2**	**0,8463 ± 0,0103**	**0,005**
Red neuronal	32 neuronas, alpha = 1	0,8461 ± 0,0105	0,010
Random Forest	500 árboles, hoja mín. 20, √p	0,8437 ± 0,0122	0,036
k vecinos	k = 151	0,8397 ± 0,0103	0,004
Árbol de decisión	profundidad 6, hoja mín. 20	0,8110 ± 0,0119	0,046

5.2 Umbral de decisión

Las probabilidades fuera del fold están calibradas (media 0,265 contra una tasa real de 0,265), también cerca del umbral: en el decil de probabilidad media 0,146 se va el 13,9%, una diferencia de 0,75 puntos, dentro del error estándar de la tasa (cerca de 1,5 puntos). Por eso el umbral teórico es válido. La curva de costo tiene forma de U y 0,134 cae en una zona plana, entre 0,10 y 0,18, a menos del 1% del mínimo (Figura 4A). Con el umbral convencional de 0,5 el modelo cuesta

más que ofrecerle la retención a todos, porque deja pasar bajas que valen siete veces y media más que una oferta: en prueba, con 0,5 alcanza solo al 52% de las bajas. En doce escenarios de costos (recuperar del 25% al 100% de la pérdida, ofertas del 10% al 20% del año) el modelo ahorra frente a la mejor estrategia sin modelo, con el umbral recalculado en cada caso: el ahorro va de 0,2% a 33%, y queda por debajo del 6% cuando la oferta retiene solo a una de cada cuatro bajas. El ahorro del caso base supone que la oferta retiene a todas las bajas contactadas.

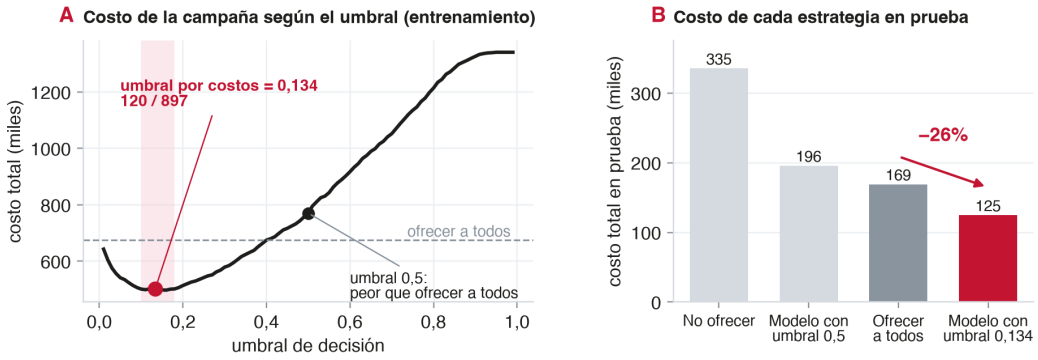


Figura 4. (A) Costo de la campaña según el umbral, con probabilidades fuera del fold; la franja marca los umbrales a menos del 1% del mínimo. (B) Costo de cada estrategia en el conjunto de prueba.

5.3 Reducción de la dimensionalidad

La primera componente principal explica el 29% de la varianza y resume antigüedad y gasto, pero sola casi no predice la baja (AUC 0,58). La segunda reproduce el perfil de riesgo del análisis exploratorio, cargo alto, fibra y contrato mes a mes frente a antigüedad y permanencia, y las bajas se concentran de ese lado (Figura 5B). Aplicamos el PCA sobre las dummies 0/1 y las numéricas escaladas: sirve para reducir la dimensión antes de un modelo lineal, aunque para describir variables categóricas lo habitual sería un análisis de correspondencias. La regla de un error estándar elige 20 componentes, que explican el 87% de la varianza, con un AUC de 0,8423 contra 0,8463 sin PCA (Figura 5A). La falta de mejora es coherente con la estructura de los datos: hacen falta 16 componentes para el 80% de la varianza. Salvo el bloque de servicios de internet, las variables están poco correlacionadas, y con más de 130 clientes por columna la logística no sobreajusta.

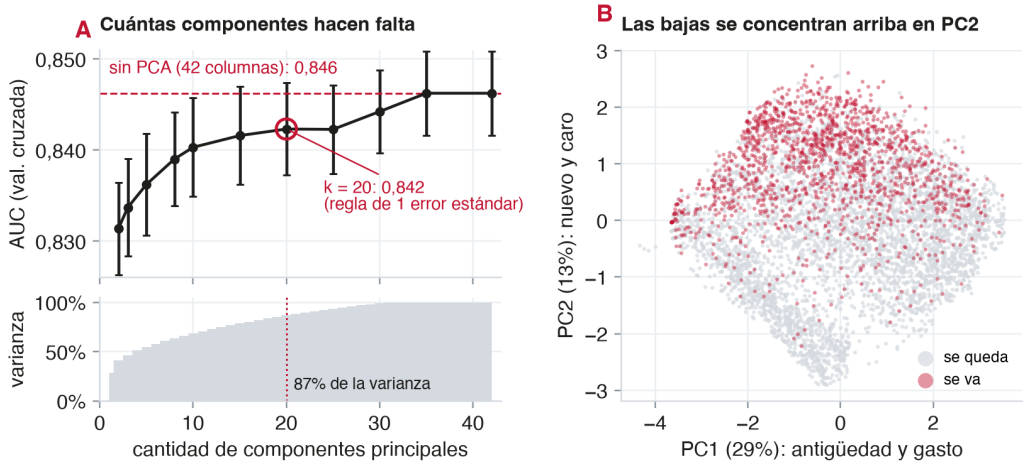


Figura 5. (A) AUC según la cantidad de componentes (± 1 error estándar; se omite k = 1, con AUC 0,58) y varianza explicada acumulada. (B) Clientes de entrenamiento en el plano de las dos primeras componentes.

5.4 Evaluación en el conjunto de prueba

El AUC de prueba (0,844) es cercano al de validación cruzada (0,846): la estimación no era optimista. La calibración también se sostiene en prueba (Brier 0,136; ningún decil se aparta más de dos errores estándar). Con el umbral de 0,134 el modelo detecta al 92% de las bajas y contacta al 57% de la cartera (Tabla 2). La precisión es baja (42,5%) y es lo esperable cuando la oferta cuesta siete veces y media menos que la pérdida: conviene más ofrecerle el descuento a un cliente que no se iba que perder a uno que sí. Frente a ofrecer la retención a todos, el ahorro es del 26% (IC 95%: 20,5% a 32,1%). El ensamble empata (diferencia de AUC −0,0001; IC −0,0027 a +0,0028) y la versión con PCA pierde 0,0056 (IC −0,0107 a −0,0007).

El modelo ordena bien: en el 10% de clientes con mayor riesgo predicho se va el 74,5%, y el 30% más riesgoso concentra dos de cada tres bajas (Figura 6A). Los coeficientes de la logística (con penalización L2 suave, C = 1) repiten lo que vimos en el análisis exploratorio. A igualdad de las demás variables, el contrato mes a mes multiplica por 3,8 las odds de baja frente al bienal (IC 95% por bootstrap: 2,8 a 5,5) y la fibra por 2,5 frente a DSL (1,7 a 3,4), mientras que la seguridad online

y el soporte técnico las reducen a dos tercios (Figura 6B). Son asociaciones y no efectos causales: no sabemos si agregarle soporte técnico a un cliente lo retendría.

Tabla 2. Resultados en el conjunto de prueba (1.409 clientes, 374 bajas) con el umbral de 0,134, salvo donde se indica.

Estrategia	AUC (IC 95%)	Detecta	Precisión	Ofertas	Costo
Regresión logística (final)	**0,844 (0,824 a 0,867)**	**0,917**	**0,425**	**807**	**124.647**
Logística con PCA (20 comp.)	0,838 (0,818 a 0,860)	0,922	0,419	823	124.773
Ensamble (contraste)	0,844 (0,823 a 0,866)	0,914	0,426	802	124.944
Logística con umbral 0,5	0,844	0,524	0,651	301	195.786
Ofrecer a todos	no aplica	1,000	0,265	1.409	169.080
No ofrecer a nadie	no aplica	0,000	no aplica	0	335.478

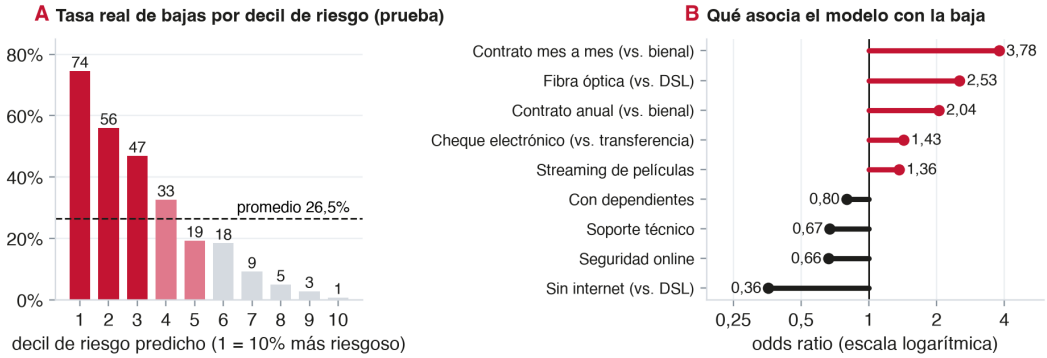


Figura 6. (A) Tasa real de bajas (%) por decil de riesgo predicho, en prueba y con el modelo ya fijado; en rojo, el 30% de mayor riesgo, que concentra dos de cada tres bajas, y en rosa, los dos deciles siguientes. (B) Odds ratios de una selección de categorías, en escala logarítmica; a la derecha de 1 aumentan el riesgo.

6. Discusión y conclusiones

- *El preprocesamiento rinde más que el modelo.* Las decisiones de preprocesamiento suben el AUC de 0,839 a 0,846, más de cuatro veces la ventaja del mejor modelo complejo, que además desaparece en prueba.
- *El umbral pesa más que el modelo.* Con el mismo modelo, pasar de 0,5 a 0,134 baja el costo en prueba un 36%; entre la logística y el ensamble, que empatan en AUC, la diferencia de costo es del 0,2% (IC 95%: −3,2% a +3,7%).
- *El PCA sirve para describir.* En este problema pierde algo de AUC, pero como herramienta exploratoria su segunda componente recupera, sin conocer la variable objetivo, el perfil de riesgo del análisis exploratorio.
- *Limitaciones.* Los costos son supuestos: la pérdida es facturación y no margen, y suponemos que la oferta retiene. El dataset no tiene dimensión temporal, así que no permite validar en el tiempo ni modelar cuándo ocurre la baja (James et al., 2023, cap. 11). Además, el modelo predice quién se va, no a quién le cambia la decisión una oferta.
- *Próximos pasos.* Usar el margen real y la tasa de aceptación de campañas anteriores, priorizar por pérdida esperada (Verbraken et al., 2013) y medir con un experimento si la oferta retiene.

7. Referencias

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.

Efron, B. y Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.

Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232.

Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3.ª ed.). O'Reilly.

Gupta, S., Hanssens, D., Hardie, B., Kahn, W., Kumar, V., Lin, N., Ravishanker, N. y Sriram, S. (2006). Modeling customer lifetime value. *Journal of Service Research*, 9(2), 139-155.

Hanley, J. A. y McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1), 29-36.

James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. y Liu, T.-Y. (2017). LightGBM: a highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.

Murphy, K. P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press.

Niculescu-Mizil, A. y Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning*, 625-632.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Verbraken, T., Verbeke, W. y Baesens, B. (2013). A novel profit maximizing metric for measuring classification performance of customer churn prediction models. *IEEE Transactions on Knowledge and Data Engineering*, 25(5), 961-973.